

# Identificación y clasificación de culícidos a través de Inteligencia Artificial

Kevin Cikel

## Abstract

Este trabajo consiste un sistema de detección e identificación de mosquitos en fase larvaria por medio del procesamiento y análisis de imágenes. Se implementó mediante la binarización de las imágenes mediante umbralización adaptativa se desarrolló un detector capaz de encotrar los objetos de interés mediante detección de contornos. Se evaluaron además dos clasificadores, uno basado en extracción de características de los objetos y clasificación mediante máquina de vector de soporte (SVM), y otro mediante la utilización de redes neuronales convolucionales (CNN).

## 1 Introducción

Los culícidos, conocidos coloquialmente como mosquitos, son insectos hematófagos considerados como unos de los mayores vectores de enfermedades infecciosas en el mundo, como el dengue, la fiebre amarilla y el zika, transmitidas por mosquitos del género Aedes, la malaria, transmitida por mosquitos del género Anopheles, y el virus del Nilo Occidental, transmitido por mosquitos del género Culex. Para el combate de estas enfermedades, los métodos para la prevención consisten en la eliminación de mosquitos en etapa adulta mediante fumigación y en el control larvario mediante la eliminación de criaderos. Por lo tanto se considera un recurso valioso para los esfuerzos de prevención el contar con datos del nivel de presencia de los distintos géneros de mosquitos en determinadas zonas geográficas. Para lograr eso, se propone la implementación de un sistema de identificación y clasificación de culícidos mediante la recolección, procesamiento y análisis de imágenes de los mismos utilizando herramientas de inteligencia artificial. En este informe se presentan los avances de un sistema de detección e identificación de culícidos en etapa larvaria en imágenes de larvas del género Aedes recolectadas en un recipiente con agua y fotografiadas en laboratorio. El sistema desarrollado tiene como objetivo la detección de los cuerpos presentes en el agua, y la identificación de mosquitos en fase larvaria entre los cuerpos detectados.

## 2 Trabajos Relacionados

La inteligencia artificial se ha convertido últimamente en la herramienta mayormente utilizada para resolver problemas de reconocimiento e identificación de objetos, principalmente mediante el empleo de redes neuronales convolucionales (CNN, por sus siglas en inglés). Uno de los modelos CNN más relevante es la red profunda residual propuesta en la arquitectura ResNet [1], mediante la cual ha sido posible entrenar efectivamente modelos de red muy profundos, desde cientos hasta más de mil capas, como la ResNet de 1002 capas entrenada con el método de profundidad estocástica propuesto en [2]. Una variante de ResNet presentada como ResNext [3] introduce una nueva dimensión denominada cardinalidad, como el número de rutas independientes a través de la red, obteniendo mejores resultados al aumentar la cardinalidad introduciendo mayor complejidad, en vez de aumentar la profundidad o el ancho de la red. El modelo DenseNet [4] introduce bloques densos, en los cuales todas las capas están directamente conectadas unas a otras, donde la entrada de cada capa consiste en el mapa de características de todas las capas precedentes, y su propio mapa de características es agregada a las entradas de todas las capas siguientes, obteniendo mejor rendimiento en comparación a modelos ResNet. En cuanto a la utilización de inteligencia artificial para diferenciación de culícidos se puede mencionar algunos trabajos, como el presentado por Sánchez y otros [5], quienes desarrollaron un clasificador binario para la diferenciación de larvas de mosquitos en dos clases, del género Aedes y de otros géneros, utilizando una CNN basado en el modelo AlexNet [6], basándose en la diferencia entre los peines ubicados en el octavo segmento de las larvas de los distintos géneros de mosquitos, obteniendo un nivel de acierto del 96.8%. Sin embargo, las imágenes de las larvas fueron capturadas de forma individual, siendo necesario la colocación de cada larva bajo una lente microscopio acoplada a la cámara. Kim y otros [7] presentan un sistema automático de detección y control de mosquitos basado en procesamiento de imágenes, atrayendo mosquitos a una plataforma de observación mediante generación de CO<sub>2</sub>. Mediante

un preprocessamiento realizado a las imágenes capturadas en esa plataforma se logró obtener las ubicaciones de los objetos presentes en la misma, utilizando una CNN basado en el modelo AlexNet para la clasificación de estos en las clases mosquito y no-mosquito. El mapa de probabilidad obtenido en la capa anterior a la etapa de desconvolución es extraída y utilizada para estimar el número de mosquitos presentes en la imagen. El trabajo desarrollado por Motta y otros [8] describe la clasificación morfológica de tres especies de mosquitos mediante la utilización de modelos de CNN entrenados con imágenes de mosquitos adultos. Se evaluaron tres modelos: LeNet, AlexNet y GoogLeNet [9], siendo este último el de mejor rendimiento obteniendo un nivel de acierto de 89.3%. Huang y otros [10] presentaron un sistema de clasificación de mosquitos capaz de catalogarlos en los géneros Aedes y Culex de forma automática. Desarrollaron un sistema IoT, compuesto por una Raspberry Pi 3 y un módulo de cámara Sony IMX219 para la captura de las imágenes de los mosquitos que son atraídos hacia una plataforma de observación. Si se detecta la presencia de objetos se envía el vídeo al servidor en donde se realiza la clasificación mediante CNN, obteniendo un nivel de acierto de 90.5% en la clasificación entre ambos géneros de mosquitos.

### 3 Detección de objetos

Antes de poder realizar la clasificación de los objetos presentes en el recipiente es necesario realizar la detección de los mismos dentro de la imagen. Como paso inicial para conseguir esto se realiza el recorte de la imagen, con el fin de reducir el tamaño de la imagen antes de aplicar los algoritmos de preprocessamiento, y se define la región de interés para descartar los objetos que se encuentren fuera del área deseada. En la Figura 1a se observa la imagen recortada y la región de interés delimitada por las líneas azules.

Posteriormente la imagen se convierte a escala de grises y se aplica un filtro gaussiano para suavizarla con el fin de reducir el ruido, y se aplica una umbralización (thresholding) adaptativa gaussiana invertida, en donde el valor umbral para cada píxel se determina mediante la suma gaussiana de los valores

de los píxeles vecinos, de esta forma se obtiene una imagen binaria con el fondo en negro y los píxeles de los objetos en blanco, como se observa en la Figura 1b.

Finalmente se realiza la detección de los objetos en la imagen binaria, para esto se aplica la función *findContours* de OpenCV, basado en el algoritmo propuesto por Suzuki y otros [11], descartando objetos muy pequeños con menos de 250 píxeles. De esta manera se obtiene la ubicación y el rectángulo delimitador de todos los objetos presentes en la imagen. En la Figura 1c se observan los objetos detectados, los señalados con un círculo verde corresponden a los que se encuentran dentro de la región de interés, mientras que los objetos que se encuentran fuera son señalados con un círculo rojo. Se observan buenos resultados, siendo detectados todos los objetos de interés en la imagen.

En la Tabla 1 se presenta la matriz de confusión del clasificador

### 4 Clasificación de objetos

Una vez detectados los objetos es necesario realizar la clasificación para descartar los objetos que no corresponden a larvas, para esto se definen las clases "no larvas", que contienen a los culícidos en etapa de pupa y otros cuerpos extraños, y "larvas" que contiene a los culícidos en etapa larvaria. El primer paso para la clasificación es el etiquetado manual en una de estas dos clases de todos los cuerpos encontrados por el detector de objetos. En total se detectaron 1440 objetos en las 45 imágenes de muestras disponibles, de los cuales 177 fueron etiquetados como no larvas y 1263 como larvas. En la Figura 2 se observan señalados con círculos rojos a los objetos etiquetados como no larvas y con círculos verdes detectados como larvas en una de las 45 imágenes de muestra.

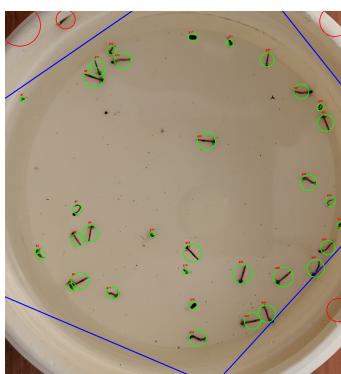
Con estos datos se realizaron las pruebas mediante clasificadores binarios utilizando dos enfoques distintos. Para el primer clasificador se emplean histogramas de gradientes orientados (HOG) para la extracción de características de cada objeto y una máquina de vector de soporte (SVM) para la clasificación de las mismas, mientras que para el se-



(a)



(b)



(c)

Figure 1: Etapas del proceso de detección de objetos.



Figure 2: Etiquetado manual de objetos en una imagen de muestra.

Table 1: Matriz de confusión del clasificador SVM.

	no larvas detectadas	larvas detectadas
no larvas reales	56	1
larvas reales	38	381

gundo clasificador se emplea una red neuronal convolucional (CNN). Para el entrenamiento de ambos clasificadores se utilizan 30 imágenes, quedando las 15 restantes para la evaluación del rendimiento.

#### 4.1 Clasificador basado en HOG y SVM

Para este clasificador se utiliza la imágenes binarias generadas por el detector de objetos, a las que se aplican operaciones morfológicas de apertura y cierre para llenar los contornos. Se aplica entonces el descriptor de características HOG para obtener los histogramas de las direcciones de los gradientes de cada objeto, los cuales se guardan en un vector de características. Mediante un clasificador SVM se obtiene el hiper-plano que discrimina a cada objeto en una de las clases según los valores del vector de características.

En la Tabla 1 se presenta la matriz de confusión y

Table 2: Valores de rendimiento del clasificador SVM

Precision	Recall	F1
0.997	0.909	0.951

en la Tabla 2 los valores de rendimiento. Se observa un valor de precisión de 0.997, lo cual indica que casi la totalidad de los objetos identificados como larvas corresponden a larvas reales. Por otra parte el valor de recuperación (recall) que se obtuvo fue de 0.909, lo que indica que aproximadamente un 9% de larvas reales fueron identificadas como no larvas.

## 4.2 Clasificador basado en CNN

Para este clasificador se utiliza una red neuronal convolucional entrenada con 30 de las imágenes. para esto se extraen las imágenes RGB de los objetos encontrados por el detector de objetos y se redimensionan a 128x128 píxeles. En la Figura 3a se muestran algunos ejemplos de objetos extraídos de la clase "larvas" y en 3b de la clase "no larvas".

El modelo de la red utilizada se muestra en la Figura 4, se compone de cuatro bloques, cada uno compuesto de una capa convolucional con una función de activación ReLU, una capa de normalización de lote (batch normalization) para reducir el sobreajuste (overfitting) y una capa de reducción (max pooling); y un último bloque compuesta por la capa completamente conectada (fully connected) con función de activación ReLU, seguida de una capa de retirados (dropout) para reducir el sobreajuste y la capa de salida con una función de activación softmax. La red es entrenada en 20 repeticiones con optimizador Nadam y función de perdida de entropía cruzada categórica dispersa (sparse categorical cross entropy).

En la Tabla 3 se presenta la matriz de confusión y en la Tabla 4 los valores de rendimiento. Se observan en este caso muy altos niveles de acierto con solo tres casos de falsos negativos y cinco de falsos positivos, obteniendo un valor F1 de 0.991.



(a)



(b)

Figure 3: Muestras de objetos detectados, (a) corresponde a la clase "larvas" y (b) a la clase "no larvas".

## 5 Conclusión

Para el sistema de identificación de larvas han sido implementados y evaluados un detector de objetos y dos clasificadores. El detector basado en umbralización adaptativa y detección de contornos ha sido capaz de encontrar la totalidad de los objetos de interés en las imágenes de muestra. Para la identificación como larva o no de cada objeto encontrado por el detector se han evaluado un clasificador basado en HOG y SVM, y otro basado en CNN, observando como medida de rendimiento valores F1 de 0.951 y 0.991 respectivamente. Se destaca el alto nivel de acierto del clasificador CNN a pesar de haber utilizado un modelo no muy complejo con pocas capas, sin embargo esto puede deberse a la limitada variedad

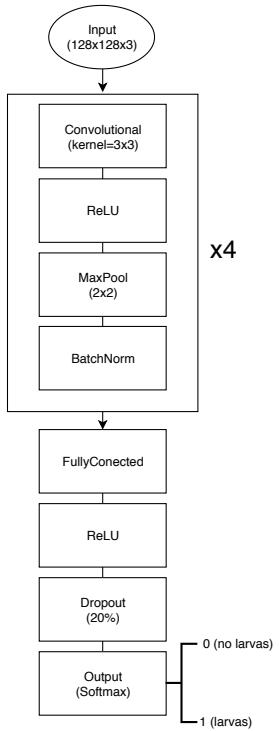


Figure 4: Modelo de la CNN utilizada.

de las imágenes, las cuales han sido utilizadas tanto para el entrenamiento como para la evaluación de los clasificadores, ya que todas han sido capturadas de la misma muestra de larvas y en el mismo día, siendo necesarias por lo tanto imágenes adicionales de muestras mas diversas para una evaluación más completa de los clasificadores.

Table 3: Matriz de confusión del clasificador CNN.

	no larvas detectadas	larvas detectadas
no larvas reales	52	5
larvas reales	3	416

## 6 Trabajos Futuros

- Obtención de imágenes adicionales de diversas muestras de larvas.
- Obtención de muestras de larvas de distintos géneros o especies de culícidos.
- Implementación de modelos de CNN más complejos.
- Desarrollo de clasificador entre distintos géneros de culícidos.
- Implementación del sistema de detección e identificación en computadora embebida.

## 7 Referencias

- [1] K. He, X. Zhang, S. Ren, and J. Sun, “Deep residual learning for image recognition,” in *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2016, pp. 770–778.
- [2] G. Huang, Y. Sun, Z. Liu, D. Sedra, and K. Q. Weinberger, “Deep networks with stochastic depth,” in *European conference on computer vision*, Springer, 2016, pp. 646–661.
- [3] S. Xie, R. Girshick, P. Dollár, Z. Tu, and K. He, “Aggregated residual transformations for deep neural networks,” in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2017, pp. 1492–1500.
- [4] G. Huang, Z. Liu, L. Van Der Maaten, and K. Q. Weinberger, “Densely connected convolutional networks,” in *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2017, pp. 4700–4708.

Table 4: Valores de rendimiento del clasificador CNN

Precision	Recall	F1
0.988	0.993	0.991

- [5] A Sanchez-Ortiz, A Fierro-Radilla, A. Arista-Jalife, M. Cedillo-Hernandez, M. Nakano-Miyatake, D. Robles-Camarillo, and V Cuatepotzo-Jiménez, “Mosquito larva classification method based on convolutional neural networks,” in *2017 International Conference on Electronics, Communications and Computers (CONIELECOMP)*, IEEE, 2017, pp. 1–6.
- [6] A. Krizhevsky, I. Sutskever, and G. E. Hinton, “Imagenet classification with deep convolutional neural networks,” in *Advances in neural information processing systems*, 2012, pp. 1097–1105.
- [7] K. Kim, J. Hyun, H. Kim, H. Lim, and H. Myung, “A deep learning-based automatic mosquito sensing and control system for urban mosquito habitats,” *Sensors*, vol. 19, no. 12, p. 2785, 2019.
- [8] D. Motta, A. Á. B. Santos, I. Winkler, B. A. S. Machado, D. A. D. I. Pereira, A. M. Cavalcanti, E. O. L. Fonseca, F. Kirchner, and R. Badaró, “Application of convolutional neural networks for classification of adult mosquitoes in the field,” *PloS one*, vol. 14, no. 1, e0210829, 2019.
- [9] C. Szegedy, W. Liu, Y. Jia, P. Sermanet, S. Reed, D. Anguelov, D. Erhan, V. Vanhoucke, and A. Rabinovich, “Going deeper with convolutions,” in *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2015, pp. 1–9.
- [10] L.-P. Huang, M.-H. Hong, C.-H. Luo, S. Mahajan, and L.-J. Chen, “A vector mosquitoes classification system based on edge computing and deep learning,” in *2018 Conference on Technologies and Applications of Artificial Intelligence (TAAI)*, IEEE, 2018, pp. 24–27.
- [11] S. Suzuki *et al.*, “Topological structural analysis of digitized binary images by border following,” *Computer vision, graphics, and image processing*, vol. 30, no. 1, pp. 32–46, 1985.